



**IMPLEMENTASI SEMANTIC SEARCH DALAM SISTEM
REKOMENDASI BUKU ONLINE GRAMEDIA MENGGUNAKAN
MODEL TEXT-EMBEDDING-004 DAN COSINE SIMILARITY**

**Tugas akhir
diajukan untuk melengkapi
persyaratan mencapai
gelar sarjana**

NAMA : Danang Hapis Fadillah

NPM : 202143500557

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNIK DAN ILMU KOMPUTER
UNIVERSITAS INDRAPRSTA PGRI**

2025

BAB II

TINJAUAN PUSTAKA

A. Landasan Teori

1. Sistem Rekomendasi


Sistem rekomendasi adalah teknologi yang dirancang untuk memberikan saran item atau konten yang sesuai dengan preferensi pengguna, sehingga dapat meningkatkan pengalaman pengguna pada platform digital seperti e-commerce, layanan streaming, maupun perpustakaan digital. Menurut Raza et al. (2024), sistem rekomendasi telah berkembang secara signifikan sejak pertama kali diperkenalkan pada tahun 1990-an, seiring dengan kemajuan dalam bidang pembelajaran mesin dan pemrosesan data.

Lebih lanjut, sistem rekomendasi secara umum dapat diklasifikasikan ke dalam tiga kategori utama, yaitu *Content-Based Filtering* (CBF), *Collaborative Filtering* (CF), dan *Hybrid Filtering* (HF). CBF berfokus pada atribut item dan preferensi pengguna, sedangkan CF memanfaatkan pola perilaku pengguna lain sebagai dasar rekomendasi. Sementara itu, pendekatan HF merupakan kombinasi dari keduanya yang bertujuan untuk meningkatkan akurasi serta mengatasi keterbatasan yang dimiliki oleh masing-masing metode secara terpisah.

Untuk memberikan gambaran menyeluruh mengenai bagaimana sistem rekomendasi berkembang dari waktu ke waktu, linimasa berikut

memperlihatkan tonggak-tonggak penting dalam evolusinya. Perkembangan ini dimulai dari sistem berbasis aturan sederhana, hingga munculnya model-model modern berbasis kecerdasan buatan yang semakin kompleks dan personal.

Gambar 2.1
Timeline of Foundational Recommender Systems



Sumber: (Raza et al, 2024)

Dengan memahami klasifikasi dasar dari sistem rekomendasi tersebut, maka pembahasan dapat difokuskan lebih lanjut pada pendekatan *Content-Based Filtering*, yang menjadi pusat perhatian dalam penelitian ini. Pendekatan ini akan diuraikan secara lebih mendalam pada sub-bagian berikutnya sebagai landasan metodologi yang digunakan.

2. *Content-Based Filtering* (CBF)

Content-Based Filtering (CBF) merupakan pendekatan dalam sistem rekomendasi yang menyarankan item berdasarkan kesesuaian antara karakteristik item dan profil preferensi pengguna. Pendekatan ini

berbeda dengan *collaborative filtering* karena tidak memerlukan data dari pengguna lain. Sebaliknya, CBF hanya mengandalkan informasi konten dari setiap item, seperti deskripsi, kategori, atau metadata, serta riwayat interaksi pengguna terhadap item-item tersebut.

Selanjutnya, setiap item direpresentasikan dalam bentuk vektor fitur $\phi(i)$, yang mencakup atribut-atribut seperti genre, kata kunci, atau sinopsis. Di sisi lain, profil preferensi pengguna direpresentasikan oleh vektor $\theta(u)$, yang dibentuk berdasarkan item yang pernah dikonsumsi atau disukai oleh pengguna, misalnya buku yang telah dibaca atau diberi penilaian tinggi.

Secara matematis, skor prediksi atau rekomendasi untuk pengguna u terhadap item i , disimbolkan dengan $\hat{r}_{ui}$, dapat dihitung menggunakan operasi *dot product* antara dua vektor, yaitu sebagai berikut:

$$\hat{r}_{ui} = \theta(u)^T \phi(i)$$

Di mana:

- $\hat{r}_{ui}$: Skor prediksi relevansi antara pengguna u dan item i .
- $\theta(u)$: Vektor preferensi pengguna u .
- T : Operasi *dot product*, yaitu perkalian dua vektor untuk mengukur tingkat kesamaan.

Dalam konteks toko buku daring, sistem CBF menganalisis elemen-elemen seperti judul, sinopsis, genre, dan tag metadata dari buku fisik yang dijual secara online untuk mengidentifikasi kemiripan antar buku. Sebagai contoh, apabila seorang pengguna sering membeli atau mencari buku fiksi ilmiah bertema eksplorasi luar angkasa, maka sistem akan merekomendasikan buku fisik lain yang memiliki karakteristik teks serupa berdasarkan kemiripan konten secara semantik.

Walaupun demikian, CBF memiliki sejumlah keunggulan. Salah satunya adalah kemampuannya memberikan rekomendasi yang bersifat personal tanpa ketergantungan pada data pengguna lain. Dengan demikian, sistem ini mampu mengatasi masalah *cold-start*, terutama bagi pengguna baru yang belum memiliki banyak interaksi sebelumnya. Namun, di sisi lain, CBF juga memiliki keterbatasan, seperti risiko *overspecialization*, yaitu kecenderungan sistem untuk hanya merekomendasikan item yang sangat mirip dengan preferensi sebelumnya. Selain itu, efektivitas sistem ini juga sangat bergantung pada kualitas dan kelengkapan data konten dari masing-masing item.

Oleh karena itu, untuk mendukung analisis konten secara optimal dalam pendekatan CBF, pemrosesan teks menjadi komponen krusial. Maka dari itu, bagian selanjutnya akan membahas peran Pemrosesan Bahasa Alami (*Natural Language Processing/NLP*) sebagai teknologi inti dalam mengelola data teks untuk sistem rekomendasi.

3. Pemrosesan Bahasa Alami (*Natural Language Processing/NLP*)

Pemrosesan Bahasa Alami (*Natural Language Processing/NLP*) merupakan cabang dari kecerdasan buatan yang berfokus pada bagaimana mesin dapat memahami, menafsirkan, dan menghasilkan bahasa manusia secara efektif. Melalui pendekatan ini, mesin dilatih untuk meniru kemampuan manusia dalam memproses bahasa, sehingga dapat menjembatani kesenjangan komunikasi antara komputer dan manusia secara alami.

Selanjutnya, NLP merupakan bidang interdisipliner yang menggabungkan ilmu komputer, linguistik, dan pembelajaran mesin. Pendekatan ini tidak hanya berfokus pada struktur bahasa, tetapi juga memperhitungkan makna, konteks, serta tujuan komunikasi dalam proses pemahaman teks oleh mesin.

Menurut Jurafsky dan Martin (2021), NLP mencakup berbagai proses pemrosesan bahasa yang beroperasi mulai dari tingkat linguistik mikro (kata) hingga tingkat makro (wacana). Proses-proses tersebut meliputi:

- ***Tokenization***: Proses pemecahan teks menjadi unit-unit kecil seperti kata, frasa, atau kalimat.
- ***Stemming dan Lemmatization***: Teknik untuk mengubah kata ke bentuk dasarnya guna normalisasi teks dan mengurangi kompleksitas kosakata.

- ***Part-of-Speech (POS) Tagging***: Proses penandaan kategori kata, seperti kata benda, kata kerja, atau kata sifat, yang berguna untuk memahami struktur sintaksis kalimat.
- ***Syntactic Parsing***: Proses analisis terhadap struktur gramatikal kalimat untuk memahami hubungan antar kata berdasarkan aturan tata bahasa.
- ***Named Entity Recognition (NER)***: Identifikasi entitas penting dalam teks, seperti nama orang, organisasi, lokasi, dan tanggal.
- ***Sentiment Analysis***: Teknik untuk mengenali opini, emosi, atau sikap subjektif yang terkandung dalam suatu teks.
- ***Semantic Modelling***: Proses pemahaman makna kata dan hubungan semantik antar kata dalam konteks tertentu.

Dengan demikian, NLP menjadi fondasi utama dalam pengolahan data berbasis teks, termasuk dalam sistem rekomendasi berbasis konten. Kemampuan untuk mengekstraksi informasi bermakna dari deskripsi buku, judul, dan metadata lainnya secara otomatis sangat penting dalam meningkatkan relevansi rekomendasi bagi pengguna.

4. Representasi Teks dan Embedding

Representasi teks merupakan proses penting dalam sistem rekomendasi berbasis konten, karena memungkinkan data teks seperti sinopsis buku diubah menjadi format numerik yang dapat diproses oleh algoritma pembelajaran mesin. Dengan demikian, sistem dapat

melakukan analisis terhadap isi buku berdasarkan struktur representasi vektornya.

Salah satu teknik representasi yang paling awal digunakan adalah *Bag-of-Words* (BoW), yang menyajikan teks sebagai vektor frekuensi kata. Dalam pendekatan ini, setiap dimensi vektor merepresentasikan sebuah kata dari kamus, dan nilai pada dimensi tersebut menunjukkan frekuensinya dalam suatu dokumen. Secara matematis, untuk suatu dokumen d dan kamus dengan n kata, vektor BoW dapat dituliskan sebagai:

$$\vec{v_d} = [f_1, f_2, \dots, f_n]$$

dengan:

f_i : Frekuensi kemunculan kata ke- i dalam dokumen d .

Namun demikian, pendekatan BoW memiliki kelemahan karena mengabaikan urutan kata dan konteks semantik. Oleh karena itu, metode lain seperti *Term Frequency-Inverse Document Frequency* (TF-IDF) digunakan untuk memperbaikinya dengan memberikan bobot lebih besar pada kata-kata yang jarang muncul dalam keseluruhan koleksi dokumen. Rumus TF-IDF didefinisikan sebagai:

$$\text{TFIDF}(t, d, D) = \text{TF}(t, d) \cdot \log \left(\frac{|D|}{\text{DF}(t, D)} \right)$$

dengan keterangan:

$TF(t, d)$: Frekuensi kata t dalam dokumen d .

$DF(t, D)$: Jumlah dokumen dalam koleksi D yang mengandung kata t .

$|D|$: Total jumlah dokumen dalam koleksi.

Meskipun demikian, teknik-teknik tradisional seperti BoW dan TF-IDF masih terbatas dalam menangkap makna semantik yang lebih dalam. Untuk itu, pendekatan modern menggunakan teknik *embedding* seperti *word embedding* dan *sentence embedding*, yang memetakan kata atau kalimat ke dalam vektor berdimensi tinggi yang merepresentasikan makna kontekstual dan hubungan semantik antar kata.

Salah satu model representasi teks yang terkenal adalah BERT (*Bidirectional Encoder Representations from Transformers*), yang diperkenalkan oleh Devlin et al. (2019). Model ini menggunakan arsitektur *transformer* untuk memproses teks secara dua arah, sehingga mampu memahami makna kata berdasarkan konteks sekelilingnya. Akibatnya, representasi vektor dari kata yang sama dapat berbeda tergantung pada kalimat tempat kata tersebut digunakan. Sebagai contoh, kata “bank” akan memiliki vektor yang berbeda dalam kalimat “bank sungai” dan “bank nasional”.

Lebih lanjut, pengembangan dari BERT seperti Sentence-BERT (SBERT), yang diperkenalkan oleh Reimers dan Gurevych (2019),

mengoptimalkan embedding pada tingkat kalimat. SBERT memanfaatkan teknik seperti *siamese* dan *triplet network* untuk menghasilkan vektor yang secara efisien merepresentasikan kemiripan semantik antar kalimat. Teknik ini sangat berguna dalam berbagai tugas seperti pencarian teks, klasifikasi, dan pengelompokan.

Dalam konteks toko buku daring, SBERT dapat digunakan untuk membandingkan sinopsis buku fisik yang dijual secara online. Hal ini memungkinkan sistem merekomendasikan buku-buku yang secara makna serupa, meskipun menggunakan kata-kata yang berbeda.

Selain itu, Cao (2024) menyoroti kemajuan terkini dalam teknologi embedding teks seperti *Gemini Embedding*, yang dirancang untuk mencapai efisiensi tinggi dan akurasi semantik yang lebih baik. Model ini dioptimalkan untuk tugas seperti pencarian, klasifikasi, dan pengelompokan teks, serta mampu menghasilkan vektor yang lebih ringkas namun tetap informatif. Dalam sistem rekomendasi buku, embedding seperti ini digunakan untuk merepresentasikan judul, deskripsi, dan kategori buku sebagai vektor dalam ruang berdimensi tinggi.

Pendekatan berbasis embedding ini terbukti lebih unggul dibandingkan metode berbasis kata kunci, karena mampu menangkap konteks dan hubungan makna yang lebih dalam. Oleh karena itu, penggunaan embedding teks menjadi komponen sentral dalam

meningkatkan akurasi dan kualitas rekomendasi pada sistem berbasis konten.

5. *Semantic Search*

Semantic search merupakan pendekatan pencarian modern yang bertujuan untuk meningkatkan relevansi hasil pencarian dengan memahami maksud (*intent*) dan konteks permintaan pengguna. Tidak seperti pencarian berbasis kata kunci yang hanya mengandalkan pencocokan literal, teknik ini berupaya menangkap makna yang terkandung dalam teks, sehingga mampu mengenali kesamaan semantik meskipun istilah yang digunakan berbeda.

Sejalan dengan pembahasan sebelumnya mengenai representasi teks, setiap kueri pengguna dan deskripsi item seperti sinopsis buku dapat dipetakan ke dalam vektor berdimensi tinggi. Vektor-vektor ini merepresentasikan makna semantik dari teks dan memungkinkan sistem mengukur kedekatan antar teks berdasarkan makna, bukan hanya kesamaan kata. Oleh karena itu, sistem tetap dapat menemukan buku yang relevan meskipun tidak mengandung kata kunci yang sama seperti yang digunakan dalam kueri pencarian.

Penerapan teknik ini sangat membantu ketika pengguna menggunakan istilah yang bervariasi untuk menyampaikan kebutuhan yang serupa. Sebagai contoh, pengguna yang mencari buku bertema “penjelajahan” mungkin akan mendapatkan rekomendasi berisi buku

dengan tema “petualangan” atau “eksplorasi dunia”, karena sistem mengenali keterkaitan semantik antar istilah tersebut berdasarkan *embedding* deskripsi masing-masing buku.

Manfaat *semantic search* semakin optimal jika dikombinasikan dengan informasi perilaku pengguna, seperti histori interaksi atau preferensi bacaan sebelumnya. Pendekatan ini memungkinkan sistem rekomendasi menjadi lebih adaptif dan personal. Bahkan, ketika informasi tentang pengguna atau item masih terbatas seperti pada kasus *cold-start*, sistem tetap dapat beroperasi secara efektif karena mengandalkan kekuatan informasi konten yang telah direpresentasikan secara semantik.

Perkembangan teknologi *embedding* terbaru, seperti yang dikembangkan oleh Cao (2024), turut memperkuat kemampuan *semantic search*. Model-model tersebut dirancang agar mampu menghasilkan vektor yang ringkas namun tetap representatif secara semantik, sehingga pencarian dapat dilakukan secara cepat dan akurat, bahkan dalam skala katalog buku yang sangat besar.

Dengan kemampuan memahami makna, menangani keragaman bahasa, dan memberikan hasil yang lebih relevan secara tematik, *semantic search* berperan penting dalam membangun sistem rekomendasi modern. Kehadirannya melengkapi metode representasi teks dan pengukuran kemiripan semantik yang telah dibahas

sebelumnya, serta menjadi fondasi dalam menyusun pengalaman pencarian yang lebih intuitif dan kontekstual bagi pengguna.

6. *Cosine Similarity*

Cosine similarity adalah metrik yang digunakan untuk mengukur kesamaan antara dua vektor dalam ruang multidimensi. Metrik ini sangat populer dalam berbagai aplikasi seperti sistem rekomendasi, pencarian teks, serta analisis data berbasis teks karena kemampuannya dalam menangkap makna semantik secara efisien. *Cosine similarity* menghitung sudut kosinus antara dua vektor, menghasilkan nilai antara -1 hingga 1. Nilai yang mendekati 1 menunjukkan kemiripan semantik yang tinggi, nilai 0 menunjukkan ketidakhubungan, sedangkan nilai mendekati -1 menunjukkan arah yang berlawanan antara dua vektor.

Menurut Wijewickrema et al. (2019), *cosine similarity* sangat efektif ketika diterapkan pada dokumen dengan kosakata teknis atau teks pendek, seperti deskripsi buku, sinopsis, atau metadata. Keunggulan ini muncul karena metrik ini mampu mengenali kesamaan makna meskipun kata-kata yang digunakan berbeda secara literal.

Secara matematis, *cosine similarity* antara dua vektor, misalnya vektor buku A $\vec{q}$ dan vektor buku B $\vec{d}_i$, didefinisikan sebagai:

$$\text{cosine similarity}(\vec{q}, \vec{d}_i) = \frac{\vec{q} \cdot \vec{d}_i}{|\vec{q}| \cdot |\vec{d}_i|}$$

dengan keterangan sebagai berikut:

- $\vec{q} \cdot \vec{d}_i$: *Dot product* antara vektor buku A dan buku B, dihitung sebagai

$$\vec{q} \cdot \vec{d}_i = \sum_{j=1}^n q_j \cdot d_{i,j}$$

dengan n sebagai dimensi vektor.

- $|\vec{q}|$: Norma Euclidean dari vektor buku A, dihitung sebagai

$$|\vec{q}| = \sqrt{\sum_{j=1}^n q_j^2}$$

- $|\vec{d}_i|$: Norma Euclidean dari vektor buku B, dihitung sebagai

$$|\vec{d}_i| = \sqrt{\sum_{j=1}^n d_{i,j}^2}$$

Dalam penerapannya pada sistem rekomendasi buku, *cosine similarity* digunakan untuk membandingkan vektor *embedding* yang mewakili konten seperti judul, deskripsi, sinopsis, atau kategori buku. Misalnya, apabila seorang pengguna mencari buku dengan tema “petualangan epik,” sistem akan membentuk vektor dari input pengguna dan membandingkannya dengan vektor deskripsi buku dalam basis data. Buku-buku dengan nilai cosine similarity tertinggi dianggap paling relevan secara semantik dan akan direkomendasikan kepada pengguna.

Pendekatan ini memungkinkan sistem untuk menemukan buku dengan tema atau gaya yang serupa, meskipun kata-kata yang

digunakan dalam deskripsi berbeda secara eksplisit. Contohnya, sistem mampu mengaitkan deskripsi “ekspedisi di hutan” dengan “petualangan di alam liar” karena kedekatan maknanya.

Selain kemampuannya dalam menangani variasi bahasa, keunggulan utama dari *cosine similarity* terletak pada interpretasi yang intuitif dan efisiensi komputasi, khususnya dalam ruang vektor berdimensi tinggi. Wijewickrema et al. (2019) juga mencatat bahwa metrik ini tahan terhadap perbedaan panjang dokumen, karena proses normalisasi memastikan bahwa perhitungan hanya mempertimbangkan arah vektor, bukan magnitudonya.

Untuk meningkatkan akurasi semantik, *cosine similarity* sering dikombinasikan dengan model embedding berbasis *transformer* seperti BERT atau Sentence-BERT. Model-model ini menghasilkan representasi vektor yang kaya makna, yang ketika dipadukan dengan metrik ini, memungkinkan platform e-commerce buku untuk memberikan rekomendasi yang lebih relevan secara tematik. Di samping itu, *cosine similarity* juga dapat digabungkan dengan metode lain seperti *collaborative filtering* untuk membentuk sistem rekomendasi hibrida yang lebih andal dan adaptif.

7. Streamlit dan Teknologi Pendukung

Streamlit merupakan *framework open-source* berbasis Python yang dirancang untuk membangun aplikasi web interaktif secara cepat dan

efisien (Streamlit Docs, 2024). Framework ini sangat cocok digunakan oleh pengembang yang ingin membuat antarmuka pengguna tanpa memerlukan keahlian mendalam dalam pengembangan web. Dengan sintaks Python yang sederhana, pengguna dapat menghasilkan aplikasi web fungsional tanpa harus menguasai HTML, CSS, atau JavaScript secara langsung.

Sebagai pendukung visualisasi data dan demonstrasi model machine learning, Streamlit menawarkan berbagai komponen antarmuka yang dapat digunakan untuk menampilkan output model secara *real-time*. Oleh karena itu, *framework* ini dipilih dalam penelitian ini untuk membangun antarmuka sistem rekomendasi buku fisik yang dijual secara daring. Antarmuka yang dikembangkan memungkinkan pengguna untuk memasukkan kueri pencarian, seperti tema atau judul buku, dan menerima hasil rekomendasi secara langsung. Hal ini bertujuan untuk memberikan pengalaman pengguna yang intuitif dan mudah diakses tanpa memerlukan pengetahuan teknis.

Untuk mendukung fungsionalitas sistem, berbagai pustaka Python digunakan dalam proses pengembangan. Pandas digunakan dalam tahap manipulasi dan pembersihan data, termasuk mengelompokkan buku berdasarkan kategori atau merapikan metadata yang tidak konsisten. Selanjutnya, NumPy dimanfaatkan dalam proses komputasi numerik, khususnya dalam perhitungan dan transformasi vektor *embedding*.

Kemudian, Scikit-learn digunakan untuk mengimplementasikan algoritma pembelajaran mesin, terutama dalam proses penghitungan kesamaan antar deskripsi buku dan pemilihan kandidat rekomendasi yang relevan.

Di samping itu, pustaka visualisasi seperti Matplotlib dan Plotly dapat diintegrasikan dengan Streamlit untuk menampilkan visualisasi data tambahan. Visualisasi ini mencakup grafik distribusi kategori buku, diagram kepadatan preferensi pengguna, atau skor relevansi hasil rekomendasi. Penyajian data secara visual bertujuan untuk meningkatkan pemahaman pengguna terhadap sistem serta mendukung proses evaluasi model.

Lebih lanjut, Streamlit menawarkan komponen antarmuka seperti input teks, *dropdown*, dan tombol interaktif yang memungkinkan pengguna mengeksplorasi sistem secara langsung. Keunggulan utama Streamlit terletak pada kemudahan integrasinya dengan berbagai pustaka Python, fleksibilitas pengembangan, serta kemampuannya untuk menghasilkan aplikasi web yang dapat dijalankan secara lokal maupun dihosting tanpa konfigurasi server yang kompleks. Dengan demikian, pemanfaatan Streamlit dalam penelitian ini memungkinkan demonstrasi sistem rekomendasi yang praktis, adaptif, dan ramah pengguna, sekaligus mendukung proses eksperimen dan pengujian algoritma dalam lingkungan yang interaktif.

B. Penelitian Relevan

No.	Peneliti (Tahun)	Judul Penelitian	Metode Penelitian	Hasil Penelitian
1.	Zhang et al. (2020)	<i>A Survey on Deep Learning Based Recommender Systems</i>	<i>Deep Learning, Transformer (BERT)</i>	Model transformer seperti BERT meningkatkan relevansi rekomendasi, terutama pada data kaya teks.
2.	Reimers & Gurevych (2019)	<i>Sentence-BERT: Sentence Embeddings Using Siamese BERT-Networks</i>	<i>Sentence-BERT</i>	Efisien untuk pencocokan semantik antar kalimat, cocok untuk rekomendasi berbasis teks.
3.	Liu et al. (2021)	<i>Enhancing Educational Recommender Systems with Knowledge Graphs and Semantic Embeddings</i>	<i>Embedding dan Knowledge Graph</i>	Kombinasi embedding dan knowledge graph meningkatkan ketepatan rekomendasi edukasi.

4.	Lee et al. (2025)	<i>Gemini Embedding: Advancements in Text Representation for Large-Scale Retrieval Tasks</i>	<i>Gemini Embedding</i>	Performa lebih baik pada pencarian dan rekomendasi dibandingkan model sebelumnya, efisien untuk dataset besar.
5.	Wang et al. (2023)	<i>Semantic Search in E-commerce: Enhancing User Experience with Contextual Relevance</i>	<i>Semantic Search</i>	Meningkatkan kepuasan pengguna dengan hasil yang relevan secara kontekstual di e-commerce.